

Previsão de Potencial Solar, Eólico e Híbrido em Pernambuco com Dados INMET e Aprendizado de Máquina

Matheus Henrique de Melo Araujo, Matheus de Lucena Henriques, Miguel Chaves Becker

CESAR School
Recife, PE, Brasil

`mhma@cesar.school, mlh@cesar.school, mcb4@cesar.school`

Abstract. This paper presents a machine learning solution for estimating solar, wind and hybrid renewable energy potential in Pernambuco, Brazil, using automatic weather station data from INMET. The project implements a reproducible data pipeline, quality reports, temporal validation, experiment tracking with MLflow and an interactive Streamlit dashboard. The models predict daily solar irradiation and wind speed, and the energy outputs are then calculated deterministically from physical constants. In the evaluated run, Random Forest achieved the best balanced NRMSE for physical targets and hybrid energy, mainly due to better wind prediction, while the climatological baseline remained stronger for solar irradiation.

Resumo. Este artigo apresenta uma solução de aprendizado de máquina para estimar o potencial de geração solar, eólica e híbrida em Pernambuco a partir de dados de estações automáticas do INMET. O projeto implementa um pipeline reprodutível de dados, relatórios de qualidade, validação temporal, rastreamento de experimentos com MLflow e dashboard interativo em Streamlit. Os modelos predizem irradiação solar diária e velocidade média do vento; as saídas energéticas são calculadas deterministicamente a partir de constantes físicas. Na execução avaliada, o Random Forest obteve o melhor NRMSE balanceado para os alvos físicos e para energia híbrida, sobretudo pela melhor previsão de vento, enquanto a baseline climatológica permaneceu mais forte para irradiação solar.

1. Introdução

O planejamento de fontes renováveis depende de estimativas consistentes de variáveis meteorológicas que afetam diretamente a geração elétrica. No caso solar, a irradiação diária determina a energia incidente nos painéis; no caso eólico, a velocidade do vento tem relação cúbica com a potência estimada. Em regiões extensas e climaticamente heterogêneas, como Pernambuco, a análise conjunta dessas fontes pode apoiar a identificação de municípios com maior aptidão para geração solar, eólica ou híbrida.

Este projeto desenvolve uma solução completa de aprendizado de máquina a partir dos dados históricos de estações automáticas do Instituto Nacional de Meteorologia (INMET). A solução cobre aquisição e padronização de dados, tratamento de qualidade, agregação em camada gold, modelagem supervisionada, rastreamento de experimentos e visualização interativa. A unidade de predição adotada é estação-dia, preservando a estrutura temporal do problema e evitando embaralhamento aleatório entre passado e futuro.

O objetivo do trabalho é comparar uma baseline climatológica com dois modelos discutidos na disciplina, Random Forest e Multilayer Perceptron (MLP), para prever irradiação solar diária e velocidade média diária do vento. A partir dessas previsões físicas, o sistema calcula geração solar, eólica e híbrida em kWh/dia com equações determinísticas. As principais contribuições são:

- um pipeline medalhão para dados INMET de Pernambuco, com camadas raw/extracted, silver e gold;
- uma estratégia de validação temporal com anos recentes reservados para teste final;
- comparação entre baseline climatológica, Random Forest e MLP com métricas físicas e energéticas;
- dashboard em Streamlit para explorar mapas, rankings, erros e séries temporais por modelo.

2. Trabalho Relacionado

O artigo usado como referência inicial foi o estudo de Ferreira et al. (2023), que propôs um índice para avaliar potencial solar, eólico e híbrido na Paraíba. Aquele trabalho usou dados públicos de estações e satélites, comparou métodos de interpolação espacial, como IDW e krigagem, e criou um ranking municipal de potencial renovável. O presente projeto mantém a motivação de apoiar decisões sobre potencial renovável no Nordeste brasileiro, mas muda o recorte metodológico: em vez de interpolar espacialmente uma grade de valores, treina modelos temporais por estação para estimar variáveis físicas e derivar a geração energética.

Essa diferença altera a principal fonte de risco metodológico. Em séries temporais meteorológicas, uma validação aleatória pode misturar registros de anos futuros no treino e produzir métricas otimistas. Por isso, a avaliação deste projeto separa os anos mais recentes como teste final e usa validação cruzada temporal expansiva dentro do período de treino.

3. Dados e Pré-processamento

A base de dados vem da página de históricos anuais do INMET, contendo arquivos CSV de estações automáticas. A execução inspecionada seleciona apenas estações de Pernambuco, resultando em 13 estações e 13 municípios. A base diária final contém 64.937 linhas estação-dia, cobrindo medições de 2003-02-20 a 2025-12-12. Após remoção de linhas sem os alvos físicos e features necessárias, os notebooks de modelagem registraram 58.022 linhas gold usadas nos experimentos.

Tabela 1. Síntese da base utilizada nos experimentos

Item	Valor observado no projeto
Fonte	INMET - dados históricos de estações automáticas
Recorte espacial	Pernambuco (UF = PE)
Estações selecionadas	13
Municípios representados	13
Intervalo temporal da base diária	2003-02-20 a 2025-12-12
Linhas estação-dia na camada gold	64.937
Linhas gold usadas na modelagem	58.022
Anos de treino/validação	2003-2020
Anos de teste final	2021-2025

A leitura dos CSVs foi implementada para lidar com variações comuns nos arquivos do INMET. O parser detecta automaticamente a linha inicial da tabela, testa encodings como UTF-8, latin1, ISO-8859-1 e CP1252, converte vírgula decimal para ponto e padroniza nomes de colunas. Valores sentinela como 9999, -9999, Null e strings vazias são tratados como ausentes. A seleção geográfica pode ser feita por UF ou por caixa delimitadora configurável, mas a execução analisada usa o modo UF para Pernambuco.

No tratamento de qualidade, velocidades de vento negativas ou acima de 75 m/s são invalidadas, assim como radiação solar negativa ou acima de 5000 kJ/m². Os horários são interpretados como UTC e convertidos para horário local por subtração fixa de três horas. Por padrão, medições de radiação solar fora do intervalo local de 05h a 18h são marcadas como ausentes antes da agregação diária. Outliers são marcados por estação e variável usando IQR, com alternativa por z-score disponível no código.

A camada gold agrega os dados horários em métricas diárias por estação: irradiação solar diária em kWh/m²/dia, média e desvio padrão da velocidade do vento, horas válidas e taxas de ausência. O dataset de aprendizado de máquina acrescenta variáveis de calendário, incluindo mês, dia do ano e codificações cíclicas por seno e cosseno.




Figura 1. Distribuição das estações automáticas selecionadas em Pernambuco.




Figura 2. Distribuição da irradiação solar diária na camada gold.




Figura 3. Série anual média da velocidade do vento nas estações selecionadas.

4. Alvos Físicos e Cálculo Energético

Os modelos não predizem diretamente kWh. Eles predizem duas variáveis físicas: irradiação solar diária (`solar_daily_kwh_m2_day`) e velocidade média diária do vento a 10 m (`wind_daily_mean_ms`). Essa escolha reduz o acoplamento entre aprendizado estatístico e hipóteses de infraestrutura, permitindo trocar constantes energéticas sem retreinar o modelo.

Após a predição, a geração solar diária é calculada como o produto entre irradiação, área dos painéis e eficiência fotovoltaica. A geração eólica usa a velocidade ajustada para altura de cubo pela lei de potência, seguida da expressão de potência cinética do vento multiplicada por 24 horas e convertida para kWh. As constantes configuradas no projeto são: área solar de 807,65 m², eficiência solar de 0,2157, área do rotor eólico de 9503,317 m², eficiência eólica de 0,46075, densidade do ar de 1,06 kg/m³, altura de referência de 10 m, altura de cubo de 105 m e expoente de cisalhamento de 0,20.

A geração híbrida é definida como a soma da geração solar e da geração eólica. Esse procedimento aparece tanto nas métricas calculadas para valores observados quanto nas métricas de previsões, garantindo que os modelos sejam comparados no mesmo espaço físico e energético.

5. Modelagem e Validação

A separação treino-teste é temporal. Os anos 2003-2020 formam o conjunto de treino e validação; os anos 2021-2025 são mantidos para teste final. Dentro do treino, a validação cruzada é expansiva por ano: os folds usam anos anteriores para treinar e o ano seguinte para validar. O Leave-One-Out não foi utilizado porque quebraria a estrutura temporal e teria custo computacional elevado para dezenas de milhares de linhas.

A baseline climatológica é um regressor determinístico baseado em médias históricas. A previsão prioriza agregados por estação e dia do ano e usa fallbacks por estação-mês, estação, dia global, mês global e média global. O mínimo configurado é de três observações para agregados diários e mensais. Essa baseline é importante porque, sem previsão meteorológica futura, parte da sazonalidade solar pode ser bem representada por padrões históricos.

Os modelos de aprendizado usam `station_code`, latitude, longitude, altitude, mês, dia do ano e codificações cíclicas de calendário. Com `USE_HISTORICAL_FEATURES` ativado, também entram estatísticas históricas dos alvos físicos, separadas por níveis `station_doy`, `station_month`, `station`, `global_doy`, `global_month` e `global`, com média, mediana, desvio padrão e contagem. Como há dois alvos físicos, isso acrescenta 48 atributos históricos aos atributos básicos.

O Random Forest foi treinado como um `RandomForestRegressor` multi-saída, sem escalonamento das variáveis numéricas. A busca ampla usou `RandomizedSearchCV` com 40 iterações e `random_state` 42, seguida de `GridSearchCV` em um espaço reduzido. Os melhores hiperparâmetros registrados foram 300 árvores, `max_depth` 12, `max_features` sqrt, `min_samples_leaf` 8, `min_samples_split` 5, `bootstrap` ativado e critério `squared_error`.

A MLP foi treinada com `MLPRegressor` multi-saída dentro de um `TransformedTargetRegressor`, com padronização das features numéricas e dos alvos. A busca ampla usou 40 iterações de `RandomizedSearchCV` e o refino usou mais 15 iterações em espaço reduzido. Os melhores hiperparâmetros registrados foram camadas ocultas (512, 256), ativação tanh, `alpha` 0,0001425635, `learning_rate` adaptative, `learning_rate_init` 0,0016427529, `batch_size` 64, `early_stopping` ativado, `validation_fraction` 0,15, `n_iter_no_change` 40 e `max_iter` 1000.

As métricas calculadas incluem MAE, RMSE, NRMSE, R^2 , viés médio, MedAE e sMAPE. O critério de seleção principal foi o `balanced_nrmse`, definido como a média do NRMSE entre os alvos avaliados. As métricas foram calculadas em dois grupos: métricas físicas para irradiação solar e vento, e métricas energéticas para geração solar, eólica e híbrida.

6. MLOps e Dashboard

Os experimentos foram rastreados com MLflow no experimento `gold_energy_potential`. O runner PowerShell cria uma pasta própria para cada execução, define variáveis de ambiente para artefatos e banco SQLite, executa os notebooks com `nbconvert` e salva notebooks executados, métricas, parâmetros, modelos e previsões em `artifacts/modeling/<run_id>`. A execução analisada tem `run_id` 20260613-134558 e consolidou três fontes de previsão: baseline, Random Forest e MLP.

O dashboard foi desenvolvido em Streamlit e consome o CSV consolidado `model_predictions_consolidated_wide_20260613-225146.csv`. A interface permite selecionar a origem da previsão entre valores reais, baseline climatológica, Random Forest e MLP. As abas implementadas exibem mapas de potencial solar/eólico/híbrido, rankings de municípios, análise de erro médio absoluto e evolução temporal das gerações estimadas.

A reprodutibilidade do ambiente está documentada por `requirements.txt` e pelo script `scripts/run_training_notebooks.ps1`.

7. Resultados e Discussão

A Tabela 2 mostra as métricas físicas no teste temporal final. O Random Forest obteve o menor NRMSE balanceado físico (0,1549), seguido pela MLP (0,1575) e pela baseline (0,1706). No entanto, essa média esconde comportamentos diferentes por alvo: a baseline foi melhor para irradiação solar, enquanto Random Forest e MLP foram melhores para vento.

Tabela 2. Métricas físicas no teste temporal final (2021-2025)

Modelo	Alvo físico	MAE	RMSE	NRMSE	R ²	sMAPE (%)
Baseline	Solar (kWh/m ² /dia)	1.341	1.697	0.165	-0.114	27.18
MLP	Solar (kWh/m ² /dia)	1.412	1.822	0.177	-0.284	30.26
Random Forest	Solar (kWh/m ² /dia)	1.398	1.822	0.177	-0.284	30.80
Random Forest	Vento (m/s)	0.685	0.885	0.133	0.299	33.44
MLP	Vento (m/s)	0.722	0.919	0.138	0.243	34.90
Baseline	Vento (m/s)	0.873	1.174	0.176	-0.235	38.18

Para irradiação solar, a baseline teve NRMSE de 0,1648 e MAE de 1,3406 kWh/m²/dia, superando Random Forest e MLP. Esse resultado é coerente com o desenho das features: sem previsão meteorológica futura, a irradiação diária fica fortemente dependente de padrões sazonais e históricos. Para vento, o Random Forest reduziu o NRMSE de 0,1764 da baseline para 0,1330 e elevou o R² de -0,2348 para 0,2986, indicando que localização, altitude, calendário e histórico capturaram estrutura útil para esse alvo.

Tabela 3. Síntese das métricas energéticas no teste temporal final

Modelo	NRMSE energético balanceado	MAE híbrido (kWh/dia)	RMSE híbrido (kWh/dia)	R ² híbrido
Random Forest	0.112	3252.1	5396.5	0.212
MLP	0.114	3505.0	5573.7	0.159
Baseline	0.118	4333.2	6450.4	-0.126

Nas métricas energéticas, o Random Forest também apresentou melhor resultado agregado: NRMSE balanceado de 0,1120 contra 0,1139 da MLP e 0,1183 da baseline. Para geração híbrida, o MAE do Random Forest foi 3252,1 kWh/dia, enquanto a baseline obteve 4333,2 kWh/dia, uma redução de aproximadamente 24,9% no erro absoluto médio. A vantagem vem principalmente da parcela eólica, pois a baseline continuou melhor na geração solar isolada.

Tabela 4. Top 5 municípios por geração híbrida média prevista pelo Random Forest no período de teste

Município	Solar (kWh/dia)	Eólica (kWh/dia)	Híbrida (kWh/dia)
-----------	-----------------	------------------	-------------------

SURUBIM	976.1	8955.0	9931.1
PETROLINA	766.9	7977.3	8744.1
ARCO VERDE	932.8	6195.5	7128.3
CARUARU	815.8	5477.2	6293.0
OURICURI	967.3	4936.2	5903.4

No ranking produzido com as previsões do Random Forest, Surubim aparece como o município com maior geração híbrida média no período de teste, seguido por Petrolina, Arco Verde, Caruaru e Ouricuri. Como a análise é baseada nas estações disponíveis, esses rankings devem ser interpretados como rankings dos pontos monitorados ou dos municípios representados pelas estações, não como um inventário espacial completo de todos os municípios pernambucanos.

A comparação com o trabalho de Ferreira et al. (2023) reforça essa limitação. O artigo-base constrói uma superfície espacial e um índice municipal, enquanto este projeto produz previsões temporais nos locais monitorados. Portanto, os resultados são mais adequados para apoiar uma dashboard operacional sobre estações e séries históricas do que para substituir uma análise geoespacial completa de potencial renovável.

8. Limitações

A primeira limitação é a cobertura espacial: apenas 13 estações de Pernambuco entraram na execução avaliada. Municípios sem estação automática não são estimados diretamente, e o projeto não aplica interpolação espacial. A segunda limitação é a ausência de variáveis meteorológicas futuras. Os modelos usam localização, calendário e histórico, mas não recebem previsões de nebulosidade, pressão, temperatura ou vento futuro, o que dificulta especialmente a predição da irradiação solar diária.

Também há limitações de tratamento temporal e energético. A conversão de UTC para horário local usa offset fixo de três horas e não modela horário de verão em períodos históricos. As estimativas de energia dependem de constantes fixas de área, eficiência, densidade do ar e altura, logo representam uma configuração tecnológica específica.

9. Conclusão

O projeto implementa uma solução de aprendizado de máquina de ponta a ponta para análise de potencial renovável em Pernambuco, desde a leitura dos dados históricos do INMET até a comparação de modelos e a visualização interativa em dashboard. A estratégia de validação temporal é adequada ao problema, pois avalia a capacidade dos modelos de generalizar para anos posteriores sem misturar futuro e passado.

Os resultados mostram que nenhum modelo domina todos os alvos. A baseline climatológica é competitiva e foi a melhor alternativa para irradiação solar, enquanto Random Forest foi superior para vento e para geração híbrida agregada. Essa evidência sugere que uma solução operacional pode manter a baseline como referência robusta para solar e usar Random Forest como modelo principal para vento e potencial híbrido. Como próximos passos, recomenda-se incorporar previsões meteorológicas ou variáveis exógenas e avaliar uma etapa geoespacial para estimar municípios sem estação própria.

Referências

Ferreira, M. M., Santos, J. A., Silva, L. R., Abrahao, R., Gomes, F. da S. V. and Braz, H. D. M. (2023). A new index to evaluate renewable energy potential: A case study on solar, wind and hybrid generation in Northeast Brazil. **Renewable Energy**, 217, 119182. <https://doi.org/10.1016/j.renene.2023.119182>.

Instituto Nacional de Meteorologia - INMET. Dados Históricos Anuais. Disponível em: <https://portal.inmet.gov.br/dadoshistoricos>. Acesso local usado pelo pipeline do projeto.

Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, 12, p. 2825-2830.

Zaharia, M. et al. (2018). Accelerating the Machine Learning Lifecycle with MLflow. **IEEE Data Engineering Bulletin**, 41(4), p. 39-45.

Streamlit Inc. Streamlit: a faster way to build and share data apps. Disponível em: <https://streamlit.io/>.